

DETECCIÓN DE ANOMALÍAS EN EL CONSUMO DE GAS NATURAL PARA CLIENTES INDUSTRIALES: UNA SOLUCIÓN ANALÍTICA PARA CONTUGAS

Alvarez Forero Fabian Camilo
Alvarez Linares Laura Alejandra
Gutierrez Garcia Carlos Alberto
Sanchez Rozo D'Sharlie

Resumen

Contugas S.A.C., filial del Grupo Energía de Bogotá, opera más de 1.836 km de gasoductos en Ica (Perú) y atiende, entre otros, a 20 clientes industriales; vigilar continuamente presión, caudal y temperatura es costoso y la compañía carece de un criterio cuantitativo que anticipe desviaciones críticas. Para convertir sus datos en una herramienta preventiva, Contugas entregó sus históricos horarios de presión, volumen y temperatura por cliente. La consultoría entrenó un Isolation Forest, algoritmo de aprendizaje automático no supervisado que aprende el comportamiento normal y señala como anómalos los registros que se aíslan con pocas particiones; la técnica maneja todas las variables a la vez, no requiere etiquetas previas y funciona con bajo coste computacional. El modelo clasifica cada lectura como “normal” o “anómala” y se integró en una interfaz tipo cuestionario que, al ingresar los valores actuales, emite un veredicto instantáneo.

Este paper explica cómo se analizaron los resultados del modelo para comprender su lógica de clasificación y contestar la pregunta de negocio: ¿qué es una anomalía en el contexto operativo de Contugas?. Mediante un análisis exploratorio de los registros marcados como atípicos se delimitaron rangos típicos por cliente, se verificaron dependencias físicas entre variables y se aislaron tres patrones recurrentes de riesgo: caudales muy bajos con presión estable, fluctuaciones leves pero persistentes en torno al caudal medio y picos de flujo acompañados de caídas de presión. Así, un histórico sin anotaciones se transforma en un sistema de alerta temprana que puede ser utilizado para prioriza inspecciones, reduce fugas o sobre-consumo y establece la base para incorporar nuevas variables hidráulicas en futuras iteraciones.

Datos disponibles y entrenamiento del modelo

Contugas entregó un único insumo para este estudio: 847.960 registros horarios (14 ene 2019 – 31 dic 2023) con la fecha, la presión [bar], la temperatura [°C] y el volumen [m³] medidos en 20 clientes industriales; cada tabla de Excel se consolidó en un único conjunto de datos de cinco columnas, sin valores nulos y sin ninguna marca que indicara eventos anómalos. Para algunos clientes se detectaron periodos con mediciones en cero o faltantes que, aunque no eran propiamente valores de operación, se incluyeron en el análisis porque podrían corresponder a fallas o daños en el equipo de medición y considerarse anomalías. Reiterando que dentro de la información proporcionada, esos detalles no fueron incluidos.

Como no teníamos ejemplos marcados de que es un registro anómalo y que no, creamos primero una guía provisional: en cada tramo de tiempo calculamos el rango típico de la variable (la franja donde cae el 50 % central de los datos) y señalamos como inusuales los valores que se alejan mucho de ese rango. Esta regla, conocida como Rolling-IQR (Inter-Quartile Range móvil), detectó en promedio un 11 % de lecturas sospechosas y solo se usó para probar y ajustar los modelos. Con esa referencia entrenamos dos métodos automáticos sin etiquetas:

- **Isolation Forest (IF):** el algoritmo genera múltiples árboles formados por divisiones aleatorias de los datos. Para cada registro cuenta cuántos niveles de división necesita recorrer antes de quedar separado del resto: si se aísla con muy pocas divisiones se clasifica como anómalo, porque su patrón difiere notablemente del comportamiento general.
- **Local Outlier Factor (LOF):** para cada registro calcula cuán densa es su vecindad comparándola con la de los puntos más cercanos. Si la densidad que lo rodea es considerablemente menor que la de sus vecinos, es decir, el punto está

“más solo” que los demás, se considera anómalo.

Se evaluaron varias configuraciones para ambos métodos. En IF se varió el parámetro contamination (porcentaje de lecturas que el modelo debe considerar atípicas) y, en LOF, el número de vecinos que se usan como referencia para medir aislamiento. Tras comparar los resultados con una validación temporal, es decir, probando el modelo en distintos tramos histórico. Se eligió Isolation Forest con contamination = 0,05: esta configuración identifica aproximadamente el 70% de las desviaciones reales y genera solo un 8.4 % de alertas, un volumen asumible para el personal de operaciones. LOF, en contraste, clasificó como anómalos más del 90% de los registros, por lo que se descartó para la implementación.

Una vez entrenado, el modelo etiqueta cada lectura nueva como “normal” o “anómala” y asigna una puntuación que indica cuán distinta es del comportamiento habitual. Esa información se aprovecha de dos maneras:

1. En una interfaz de consulta donde el operario ingresa presión, caudal y temperatura y recibe al instante un veredicto.
2. En el análisis descriptivo de este paper, que muestra por qué el modelo considera atípicos ciertos patrones y qué rangos deben vigilar los técnicos para priorizar sus inspecciones.

Análisis exploratorio de anomalías

El modelo Isolation Forest entrega una señal binaria (“normal” / “anómalo”) y un puntaje de rareza. El objetivo del análisis es interpretar esa salida: saber cuántas lecturas quedaron marcadas como atípicas, en qué clientes se concentran y qué patrones físicos comparten, de modo que el equipo operativo pueda traducir la alerta en acciones concretas.

El modelo analizó 847.960 registros históricos (2019-2023) y señaló 21.199 lecturas como anómalas, lo que corresponde a aproximadamente

el 2,5 % del total (una de cada cuarenta mediciones). Esta cifra establece el punto de partida para los análisis posteriores: a partir de esas 21.199 alertas se investigará en qué clientes se concentran y qué patrones operativos comparten.

Panorama general de las anomalías

El conjunto de 21.199 lecturas etiquetadas como atípicas se examinó con dos recursos que resultan prácticos para contrastar “lo normal” frente a “lo anómalo”:

Distribuciones con gráficas de violín:

Una gráfica de violín muestra, en un solo trazo, qué tan concentrados o dispersos están los valores de cada variable. Al superponer la franja “normal” y la franja “anómala” para presión, caudal y temperatura, se observa que las alertas se disparan principalmente cuando la presión cae por debajo de ~5 bar o supera ligeramente los 18 bar, y cuando el caudal entra en una zona intermedia-alta (100–150 m³) que rara vez aparece en la operación corriente. La temperatura por sí sola raramente activa la alarma; solo acompaña a otros desvíos cuando roza sus valores más altos (~30 °C). Con este contraste el operador visualiza, sin fórmulas, qué rangos concretos está usando el sistema para decidir que una medición “se sale de la línea”.




Figura 1. Gráfica de Violín para categoría de anomalía para el Volumen (Fuente propia)




Figura 2. Gráfica de Violín para categoría de anomalía para la Temperatura (Fuente propia)




Figura 3- Gráfica de Violín para categoría de anomalía para la Presión (Fuente propia)

Relaciones con un mapa de calor de correlaciones

Para entender cómo se combinan las variables en las lecturas anómalas se calculó una matriz de correlación y se representó como mapa de calor. El cálculo incluyó no solo las tres variables originales, sino también todas las transformaciones empleadas en el modelo:

- Horas, días y fines de semana para capturar ciclos.
- Versiones “seno” y “coseno” de esas variables horarias para representar la curva diaria.
- Cocientes y productos físicos entre presión, caudal y temperatura para representar relaciones.
- Transformaciones logarítmicas y estadísticos simples por fila.

El mapa (Figura 4) confirma que en las lecturas anómalas presión y caudal mantienen una relación negativa clara: cuando la demanda sube la presión tiende a bajar. Mientras que la temperatura apenas

se correlaciona con las otras señales. Las variables derivadas repiten este comportamiento y refuerzan la misma pauta, lo que explica por qué el modelo

es especialmente sensible a combinaciones de gran volumen con pérdida de presión.




Figura 4. Mapa de Correlación de variables para todo el grupo de anomalías (Fuente propia)

En conjunto, la comparación de distribuciones y la lectura de correlaciones indican que el modelo considera anómalas, sobre todo, las mediciones donde la presión abandona su banda segura o el caudal opera en un rango intermedio-alto poco frecuente, mientras que la temperatura desempeña un papel secundario. Conocer estos límites y relaciones proporciona el contexto necesario para interpretar las alertas antes de revisar el detalle por cliente.

Distribución de anomalías

Para conocer dónde se concentran los 21.199 registros marcados como atípicos, se calculó para cada cliente:

- Tasa de anomalías: proporción de sus propias lecturas que el modelo considera inusuales.
- Participación en el total: porcentaje de anomalías de ese cliente sobre las 21.199 alertas globales.

Al revisar los resultados registrados en la Tabla 1, se tiene que:

- Hay una concentración de anomalías, ya que los clientes 3, 14 y 19 generan cerca del 70 % de las 21.199 alertas. Esto evidencia que las desviaciones no se reparten de forma uniforme: el fenómeno anómalo se concentra en pocos puntos de la red.
- La tasa media de anomalía en toda la red es 2,5 %, pero el Cliente 3 alcanza un 17 %. Una cifra tan alta indica que, para este cliente, el patrón de consumo y condiciones de operación difieren con

mucha más frecuencia del comportamiento que el modelo considera normal.

- Los clientes 1, 6, 9 y 16 no presentan ninguna alerta a lo largo del período analizado; sus variables permanecen dentro de los rangos que el modelo aprendió como típicos.

En la Figura 5 y Figura 6 se ilustran esta diferencia de forma visual a través de barras. Conocer esta distribución permite comprender en qué puntos el modelo encuentra más desviaciones y cuán intensas son dentro de cada cliente.

Tabla 1. Distribución de anomalías por cliente

Cliente	Registros totales	Registros anómalos	Tasa interna de anomalías	% del total de anomalías
CLIENTE 3	42 248	7 237	17,13 %	34,14 %
CLIENTE 14	43 415	4 340	10,00 %	20,47 %
CLIENTE 19	42 305	2 905	6,87 %	13,77 %
CLIENTE 7	41 776	1 449	3,47 %	6,84 %
CLIENTE 8	43 147	1 366	3,17 %	6,44 %
CLIENTE 15	42 428	1 139	2,68 %	5,37 %
CLIENTE 11	42 248	1 050	2,49 %	4,95 %
CLIENTE 20	42 808	617	1,44 %	2,91 %
CLIENTE 5	43 415	428	0,99 %	2,02 %
CLIENTE 18	41 382	283	0,68 %	1,33 %
CLIENTE 17	43 412	176	0,41 %	0,83 %
CLIENTE 13	41 059	148	0,36 %	0,70 %
CLIENTE 2	41 382	30	0,07 %	0,14 %
CLIENTE 10	41 059	25	0,06 %	0,12 %
CLIENTE 4	42 305	5	0,01 %	0,02 %
CLIENTE 12	41 776	1	0,00 %	0,00 %
CLIENTE 1	43 412	0	0,00 %	0,00 %
CLIENTE 6	42 808	0	0,00 %	0,00 %
CLIENTE 9	42 428	0	0,00 %	0,00 %
CLIENTE 16	43 147	0	0,00 %	0,00 %




Figura 5. Tasa de anomalías por cliente (Fuente propia)




Figura 6. Porcentaje de anomalías de cada cliente respecto al total (Fuente propia)

Comportamiento por cliente

El modelo detecta 21.199 anomalías repartidas en solo 20 clientes industriales; con un número tan acotado es posible revisar cada caso y precisar qué valores considera “fuera de rango”. En redes

con cientos de usuarios esta inspección uno-a-uno no escalaría.

Para fijar qué valores considera “fuera de rango” el sistema usamos tres herramientas complementarias, fáciles de interpretar: las gráficas

de violín, que combinan en una sola figura el rango habitual y la forma completa de la distribución, mostrando de un vistazo si las lecturas anómalas se agrupan en presiones muy bajas, picos de caudal o franjas intermedias poco frecuentes; el mapa de calor de correlaciones, aplicado a los tres clientes con más alertas, que colorea la relación entre variables y deja claro, por ejemplo, que un gran caudal suele ir acompañado de una caída de presión; y la frecuencia media entre alertas, que traduce esos patrones en tiempo y dice cada cuántas horas reaparecen.

Juntas, estas tres herramientas responden a la pregunta práctica: ¿qué valores, en qué combinaciones y con qué regularidad sacan al sistema de su comportamiento normal?; su lectura ofrece una guía directa para entender, cliente por cliente, por qué el modelo dispara la alarma.

A continuación se presentan los resultados por cliente, las gráficas de violín y mapas de calor, se añaden en los anexos:

Tabla 2. Comportamiento de anomalías por cliente

Cliente	Rangos específicos que el modelo marca como anómalos	Horas entre alertas (media)	Patrón que dispara la alerta
C-3	Presión por debajo de 3,5–3,7 bar.	6	Caída en la presión. <i>Correlación:</i> alta relación caudal ↑ – presión ↓, a mayor caudal, menor presión; La temperatura y tiempo no influyen.
C-14	Temperatura en el tramo alto 26–30 °C con caudal medio (5–6 m³)	10	Oscilación térmica al alza. <i>Correlación:</i> volumen y temperatura suben juntos; más eventos en fines de semana; presión no es determinante.
C-19	Caudal muy bajo 0–10 m³; temperatura 26–29 °C y presión 17,6–17,9 bar (extremo alto).	15	Flujo casi nulo con repunte térmico moderado y presión alta. <i>Correlación:</i> combinación volumen bajo × temperatura alta; presión–volumen sin relación clara.
C-7	Presión baja 16,5–17,0 bar con caudal 70–90 m³, temperatura 24–26 °C.	30	Descenso de presión por debajo de su banda.
C-8	Caudal relativamente bajo-medio 40–80 m³ frente a su rango normal 20–250 m³.	31	Flujo reducido; presión y temperatura casi constantes.
C-15	Caudal salta de < 5 m³ a 5–15 m³.	37	Incremento repentino en un caudal normalmente bajo.
C-11	Temperatura 23–26 °C (parte baja); caudal y presión apenas varían.	40	Descenso térmico moderado.
C-20	Caudal 10–60 m³ frente a normales 200–240 m³; temperatura 22–24 °C; presión 16,8–17,2 bar.	71	Flujo drásticamente reducido con ligero enfriamiento y caída de presión.
C-5	Temperatura cae a ~15 °C; caudal < 10 m³; presión casi constante.	86	Descenso térmico pronunciado acompañado de bajo flujo.
C-18	Caudal baja a 40–60 m³; presión 16,2–16,6 bar; temperatura 27–29 °C.	66	Flujo reducido con pequeña baja de presión.
C-17	Caudal 18–22 m³; presión 16,9–17,2 bar; temperatura 22–25 °C.	230	Descensos simultáneos y moderados de caudal y presión.
C-13	Caudal muy bajo 0–10 m³; presión 17,3–17,5 bar; temperatura casi estable.	279	Bajo flujo con leve caída de presión.
C-2	Caudal intermedio 40–70 m³ con presión fuera de banda estrecha con caídas 16–16,5 bar y picos 17,8–18,2 bar; temperatura 24–28 °C.	1 347	Volumen intermedio + presión fuera de su banda habitual; los cambios de presión son el factor más visible.
C-10	Caudal muy bajo 0–30 m³ frente a picos normales 200–300 m³.	1 593	Consumos anormalmente bajos.
C-4	Caudal salta a 200–300 m³ desde < 10 m³; ligeras variaciones de presión y temperatura.	8 356	Pico brusco de volumen.
C-12	Temperatura fija en 32 °C; caudal y presión constantes.	—	Valor térmico aislado fuera del patrón.
C-1	—	—	Sin anomalías.

Cliente	Rangos específicos que el modelo marca como anómalos	Horas entre alertas (media)	Patrón que dispara la alerta
C-6	—	—	Sin anomalías.
C-9	—	—	Sin anomalías.
C-16	—	—	Sin anomalías.

El balance cliente a cliente confirma que la “anomalía” adopta formas distintas según el grupo: en el cliente 3 prima la caída de presión (< 5 bar); en el cliente 14 la alerta la dispara la temperatura alta (26–30 °C) con caudal medio y mayor ocurrencia en fin de semana; y en el cliente 19 predominan caudales casi nulos acompañados de temperatura y presión en el extremo alto de su rango. Un segundo grupo clientes 8, 7 y 15 presentan variaciones más suaves: descensos moderados de presión o saltos del caudal respecto a su línea normal. Otros casos puntuales incluyen picos aislados de volumen (cliente 4), descensos térmicos pronunciados (cliente 5) o valores térmicos únicos fuera de patrón (cliente 12). Por último, los clientes 1, 6, 9 y 16 en lo que respecta a presión, temperatura y caudal operan sin registros atípicos. Estas diferencias surgen porque el modelo compara cada lectura con el historial propio de su cliente: lo que resulta crítico para un cliente puede ser parte de la variabilidad aceptable de otra. De ahí la utilidad de este desglose, que complementa la visión global y especifica cómo se manifiesta la anomalía en cada punto de la red.

Agrupamiento de anomalías (Clustering)

Aunque revisar anomalías cliente a cliente aporta un gran nivel de detalle, cuando se cuenta con miles de alertas de decenas de puntos ese enfoque deja de ser práctico y dificulta obtener una visión unificada de lo que sucede en toda la red. Para solventar esta limitación utilizamos un método de clustering, un sistema de aprendizaje automático que agrupa lecturas con patrones similares de presión, caudal y temperatura en conjuntos de casos comparables. Tras un análisis de diferentes configuraciones para determinar la agrupación más representativa, condensamos toda la información

en unas pocas categorías operativas. Esta estrategia no solo permite identificar de forma rápida y coherente los desvíos más frecuentes en el conjunto de anomalías, sino que también facilita la estandarización de las respuestas y agiliza la toma de decisiones a gran escala.

Selección del número de clusters

Para decidir cómo agrupar las 21.199 lecturas anómalas en categorías útiles, primero exploramos visualmente cómo mejoraba la unión de puntos al aumentar la cantidad de conjuntos: trazamos la gráfica de codo (Elbow Plot), que muestra la reducción de la distancia interna promedio al añadir más grupos. Luego comprobamos la calidad de separación con el coeficiente de silueta (Silhouette Score), que mide qué tan distintos están los grupos entre sí.

En la gráfica de codo (Figura 7) observamos que, al ir de dos a tres grupos, la reducción en la distancia promedio de cada punto a su centro es muy pronunciada, mientras que a partir de tres grupos esa mejora se hace casi imperceptible; ese “doblez” en la curva señala claramente que tres clusters es un buen punto de partida. En contraste, la gráfica de silueta (Figura 7), que representa qué tan bien separados y compactos quedan los grupos, alcanza su valor máximo en cinco clusters, lo que sugiere un modelo más fragmentado pero con agrupaciones muy nítidas. Dado que nuestro objetivo era equilibrar claridad operativa y simplicidad de respuesta, hicimos pruebas iterativas y confirmamos que tres clusters ofrecían el mejor compromiso: agrupan las 21.199 alertas en categorías suficientemente distintas para identificar patrones comunes, sin multiplicar excesivamente los tipos de anomalía que el equipo debe aprender a reconocer.




Figura 7. Gráfica de Codo y de Silueta (Fuente propia)

Descripción de los clusters

Para agrupar las 21.199 lecturas anómalas utilizamos un enfoque que combina tanto los valores de presión, caudal y temperatura como la identidad del cliente (codificada numéricamente), de modo que el agrupamiento refleje tanto patrones físicos como diferencias entre estaciones.

- K-means: aplicamos este método de partición sobre el espacio formado por las tres medidas y la variable cliente, de modo que cada lectura se asigna al centro o promedio de esos cuatro atributos más próximo. Esto garantiza que, además de las condiciones operativas, la pertenencia a cada estación influya en la definición de grupos homogéneos de anomalías.
- PCA (Análisis de Componentes Principales): transformamos las cuatro dimensiones iniciales en dos ejes (PC1 y PC2) que concentran la mayor parte de la variabilidad y permiten visualizar de forma clara la separación entre los clusters resultantes.

Con esta combinación confirmamos que los grupos definidos por K-means capturan patrones comunes de anomalías y diferencian claramente tanto el comportamiento de presión, caudal y temperatura como la distribución de los clientes en cada tipo operativo.

Los tres grupos que describen el comportamiento de las anomalías son:

- Cluster 0 : Flujo muy bajo con presión estable.

Tiene 340 registros, lo que equivale aproximadamente al 1.6% de las anomalías. Este grupo selecciona registros únicamente del Cliente 7 y se caracteriza porque la presión (~ 17.5 bar) y la temperatura (~ 23 °C) permanecen prácticamente idénticas a la operación normal, pero el volumen cae bruscamente a un promedio de ~ 17 m³ (frente a 40–120 m³ en los otros clusters). En el gráfico de PCA (puntos azules - Figura 8), estas lecturas se concentran alrededor de PC1 ≈ -2.0 y PC2 $\approx +0.5$, lo que muestra que el volumen reducido es la señal distintiva. Operativamente, estas alertas señalan caudales inusualmente bajos con presión y temperatura estables.

- Cluster 1: Desviaciones ligeras pero persistentes en el volumen

Tiene 12.566 registros, lo que equivale aproximadamente al 60% de las anomalías. Reúne anomalías de 14 clientes (2, 4, 5, 8, 10, 12–15, 17–20) y es el más numeroso. Sus centroides indican presiones estables (~ 17.4 bar) y temperaturas moderadas (~ 25.4 – 25.5 °C), pero volúmenes intermedios (~ 40 m³). En el PCA (puntos naranjas - Figura 8) forma una nube amplia centrada en PC1 $\approx +1.0$ y PC2 ≈ 0 . Esta agrupación

corresponde a desviaciones ligeras pero persistentes en el caudal medio, sin caídas drásticas de presión ni picos extremos, que pueden reflejar ajustes operativos fuera de su rango habitual.

- Cluster 2: Picos de caudal con caída de presión

Tiene 8.293 registros, lo que equivale aproximadamente al 38% de las anomalías. Incluye anomalías de Cliente 3

11 y 2, y se define por volúmenes muy elevados (centroide $\sim 126 \text{ m}^3$), presiones bajas ($\sim 3.55 \text{ bar}$) y temperaturas altas ($\sim 25.4 \text{ }^\circ\text{C}$). En el PCA (puntos verdes - Figura 8) estos registros quedan alrededor de $\text{PC1} \approx -1.5$ y $\text{PC2} \approx +1.5$, claramente separados de los demás. Corresponden a picos de flujo extremos que hacen caer la presión por debajo de lo normal, señalando situaciones de sobreconsumo súbito o posibles fugas importantes.




Figura 8. Distribución de Clusters (PCA)

Conclusiones

Este estudio demuestra que, partiendo de un histórico sin etiquetas, es posible convertir miles de lecturas de presión, caudal y temperatura en una herramienta práctica de alerta temprana. El modelo Isolation Forest aprendió el comportamiento normal y señaló con un 2,5 % de alertas aquellas lecturas fuera de rango, que luego se interpretaron mediante exploración visual (violines y mapas de

calor) y agruparon en tres tipos operativos. El análisis global evidenció que las anomalías suelen corresponder a caídas de presión extremas, picos o valles de flujo intermedios-altos, mientras la temperatura actúa en apoyo. Llevado al detalle de cada cliente, este enfoque reveló que lo que dispara una alerta en una estación (por ejemplo, presión $< 5 \text{ bar}$ en Cliente 3) puede ser perfectamente normal en otra. Finalmente, el clustering simplificó las 21.199 alertas en tres

categorías comprensibles, estandarizando la forma en que el personal técnico reconoce y clasifica un desvío, y sentando las bases para protocolos de inspección más ágiles y focalizados.

Líneas de mejora y próximos pasos

Para aumentar la precisión y relevancia de la detección de anomalías, recomendamos enriquecer el modelo con:

- Etiquetas de eventos reales: incorporar datos históricos de fallas confirmadas, rupturas o mantenimientos programados para diferenciar anomalías críticas de variaciones benignas.
- Información de equipos: sumar registros de daños o reemplazos de medidores, ya que una lectura en cero o faltante a


menudo refleja un fallo de hardware más que un evento operativo.

- Características del entorno: añadir variables geográficas y topográficas (altitud, pendiente del terreno) y datos del material y diámetro de las tuberías, para capturar efectos de fricción o expansión térmica que influyen en presión y caudal.
- Variables operativas adicionales: integrar datos de flujo acumulado, presión de suministro y etiquetas de turno o consumo por proceso, de modo que el modelo distinga entre ciclos de producción y eventos inesperados.

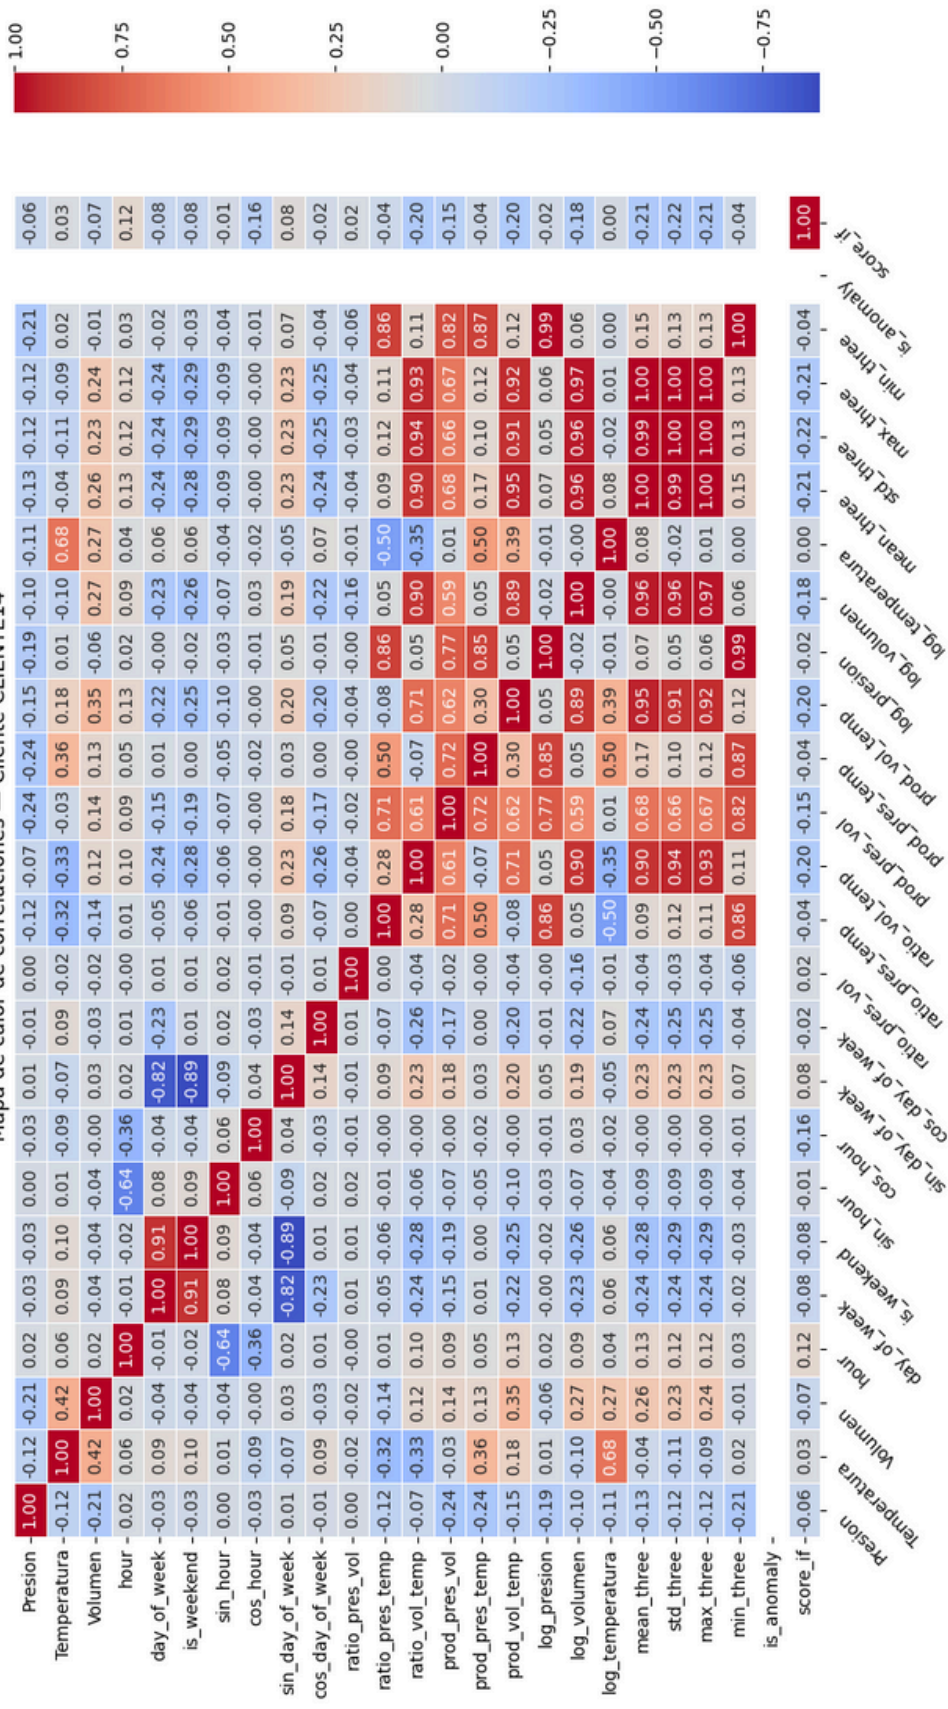
Con estos insumos, el sistema podrá refinar sus criterios, reducir falsos positivos y ofrecer un diagnóstico más completo, adaptado a las particularidades físicas y operativas de la red de Contugas.

ANEXOS

Presion	-1.00	-0.11	-0.56	-0.00	0.09	0.11	-0.02	-0.01	-0.08	0.07	0.41	0.18	-0.24	-0.31	-0.06	-0.35	0.45	-0.38	-0.12	-0.34	-0.33	0.45	0.11
	Temperatura	-0.11	1.00	0.06	0.03	0.12	0.10	-0.04	-0.00	-0.10	-0.02	0.06	-0.87	-0.51	-0.08	0.91	0.41	-0.00	-0.07	0.91	0.01	-0.11	-0.08
Volumen	-0.56	0.06	1.00	0.02	-0.07	-0.08	-0.02	0.02	0.06	-0.05	-0.25	-0.12	0.15	0.20	0.04	0.23	-0.30	0.24	0.08	0.22	0.21	0.21	-0.30
	hour	-0.00	0.03	0.02	1.00	-0.04	-0.04	-0.69	-0.21	0.04	-0.02	-0.05	-0.03	0.09	0.11	0.01	0.11	-0.07	0.09	0.02	0.12	0.12	-0.07
day_of_week	-0.09	0.12	-0.07	-0.04	1.00	0.87	0.07	-0.07	-0.78	-0.20	0.17	-0.11	-0.30	-0.26	0.13	-0.17	0.12	-0.23	0.12	-0.25	-0.27	-0.26	0.12
is_weekend	-0.11	0.10	-0.08	-0.04	0.87	1.00	0.09	-0.08	-0.87	0.07	0.21	-0.08	-0.34	-0.32	0.11	-0.23	0.14	-0.28	0.09	-0.31	-0.33	-0.32	0.14
sin_hour	-0.02	-0.04	-0.02	-0.69	0.07	0.09	1.00	0.00	-0.08	0.03	0.01	0.04	-0.04	-0.06	-0.03	-0.07	0.03	-0.04	-0.04	-0.07	-0.06	-0.07	0.03
cos_hour	-0.01	-0.00	0.02	-0.21	-0.07	-0.08	0.00	1.00	0.11	-0.01	-0.04	0.00	0.01	0.01	0.01	0.01	-0.01	0.02	-0.00	0.01	0.01	0.01	-0.01
sin_day_of_week	-0.08	-0.10	0.06	0.04	-0.78	-0.87	-0.08	0.11	1.00	0.08	-0.17	0.08	0.31	0.28	-0.10	0.19	-0.11	0.24	-0.09	0.27	0.29	0.29	-0.11
cos_day_of_week	-0.07	-0.02	-0.05	-0.02	-0.20	0.07	0.03	-0.01	0.08	1.00	0.10	0.04	-0.09	-0.12	-0.02	-0.12	0.06	-0.12	-0.03	-0.12	-0.12	-0.12	0.06
ratio_pres_vol	-0.41	0.06	-0.25	-0.05	0.17	0.21	0.01	-0.04	-0.17	0.10	1.00	0.15	-0.73	-0.84	0.05	-0.73	0.57	-0.34	-0.04	-0.84	-0.83	-0.84	0.57
ratio_pres_temp	-0.18	-0.87	-0.12	-0.03	-0.11	-0.08	0.04	0.00	0.08	0.04	0.15	1.00	0.35	-0.12	-0.94	-0.61	0.24	-0.15	-0.98	-0.23	-0.10	-0.13	0.24
ratio_vol_temp	-0.24	-0.51	0.15	0.09	-0.30	-0.34	-0.04	0.01	0.31	-0.09	-0.73	0.35	1.00	0.87	-0.53	0.49	-0.43	0.85	-0.45	0.82	0.89	0.87	-0.43
prod_pres_vol	-0.31	-0.08	0.20	0.11	-0.26	-0.32	-0.06	0.01	0.28	-0.12	-0.84	-0.12	0.87	1.00	-0.06	0.85	-0.45	0.97	0.03	0.99	1.00	1.00	-0.46
prod_pres_temp	-0.06	0.91	0.04	0.01	0.13	0.11	-0.03	-0.01	-0.10	-0.02	0.05	-0.94	-0.53	-0.06	1.00	0.45	0.09	-0.06	0.99	0.04	-0.10	-0.06	0.09
prod_vol_temp	-0.35	0.41	0.23	0.11	-0.17	-0.23	-0.07	0.01	0.19	-0.12	-0.73	-0.61	0.49	0.85	0.45	1.00	-0.47	0.83	0.54	0.90	0.83	0.85	-0.48
log_presion	-0.45	-0.00	-0.30	-0.07	0.12	0.14	0.03	-0.01	-0.11	0.06	0.57	0.24	-0.43	-0.45	0.09	-0.47	1.00	-0.56	-0.07	-0.52	-0.51	-0.52	1.00
log_volumen	-0.38	-0.07	0.24	0.09	-0.23	-0.28	-0.04	0.02	0.24	-0.12	-0.94	-0.15	0.85	0.97	-0.06	0.83	-0.56	1.00	0.04	0.97	0.97	0.97	-0.56
log_temperatura	-0.12	0.91	0.08	0.02	0.12	0.09	-0.04	-0.00	-0.09	-0.03	-0.04	-0.98	-0.45	0.03	0.99	0.54	-						



Mapa de calor de correlaciones — Cliente CLIENTE14



Presion	-1.00	0.14	-0.02	0.05	-0.14	-0.15	-0.12	-0.01	0.14	-0.05	-0.07	-0.22	0.16	0.39	0.32	0.25	0.12	0.35	0.15	0.09	0.11	0.25	
	Temperatura	-0.14	1.00	-0.02	-0.05	-0.28	-0.28	0.04	0.06	0.24	-0.09	-0.14	-0.83	-0.62	0.09	0.81	0.66	-0.14	0.12	0.83	0.21	0.07	0.11
Volumen	-0.02	-0.02	1.00	0.00	0.07	0.11	-0.01	0.00	-0.08	0.09	0.04	0.02	-0.01	-0.03	0.04	-0.04	-0.01	-0.04	-0.03	0.03	0.04	-0.04	
	hour	-0.05	-0.05	0.00	1.00	-0.10	-0.11	-0.74	0.08	0.10	-0.02	-0.03	0.02	0.03	0.02	0.00	-0.01	0.03	-0.02	0.02	0.02	0.02	-0.01
day_of_week	-0.14	-0.28	0.07	-0.10	1.00	0.85	0.12	-0.19	-0.80	-0.04	0.29	0.26	0.03	-0.30	-0.28	-0.38	-0.00	-0.30	-0.28	-0.32	-0.28	-0.29	-0.00
	is_weekend	-0.15	-0.28	0.11	-0.11	0.85	1.00	0.11	-0.19	-0.84	0.32	0.33	0.26	-0.00	-0.34	-0.28	-0.41	-0.01	-0.34	-0.28	-0.36	-0.31	-0.33
sin_hour	-0.12	0.04	-0.01	-0.74	0.12	0.11	1.00	-0.04	-0.11	-0.01	0.06	0.01	-0.02	-0.06	-0.01	-0.05	0.00	-0.06	-0.01	-0.06	-0.06	0.00	0.00
	cos_hour	-0.01	0.06	0.00	0.08	-0.19	-0.19	-0.04	1.00	0.19	-0.01	-0.21	-0.05	0.10	0.26	0.09	0.21	0.08	0.25	0.07	0.25	0.24	0.08
sin_day_of_week	-0.14	-0.08	0.10	-0.08	-0.80	-0.84	-0.11	0.19	1.00	-0.12	-0.30	-0.23	0.00	0.31	0.25	0.37	0.01	0.31	0.25	0.32	0.29	0.30	0.01
	cos_day_of_week	-0.05	-0.09	0.09	-0.02	-0.04	0.32	-0.01	-0.01	-0.12	1.00	0.14	0.07	-0.03	-0.12	-0.07	-0.13	0.03	-0.13	-0.07	-0.13	-0.12	-0.13
ratio_pres_vol	-0.07	-0.14	0.04	-0.03	0.29	0.33	0.06	-0.21	-0.30	0.14	1.00	0.20	-0.52	-0.90	-0.06	-0.71	0.40	-0.98	-0.14	-0.96	-0.96	-0.97	0.40
	ratio_pres_temp	-0.30	-0.83	0.02	0.02	0.26	0.26	0.01	-0.05	-0.23	0.07	0.20	1.00	0.72	-0.13	-0.94	-0.78	0.17	-0.17	-0.99	-0.27	-0.11	-0.16
ratio_vol_temp	-0.22	-0.62	-0.01	0.03	0.03	-0.00	-0.02	0.10	0.00	-0.03	-0.52	0.72	1.00	0.55	-0.75	-0.16	-0.10	0.55	-0.74	0.46	0.60	0.56	-0.10
	prod_pres_vol	-0.16	0.09	-0.03	0.02	-0.30	-0.34	-0.06	0.26	0.31	-0.12	-0.90	-0.13	0.55	1.00	0.13	0.71	0.00	0.97	0.13	0.98	0.98	0.00
prod_pres_temp	-0.39	0.81	-0.01	-0.02	-0.28	-0.28	-0.01	0.09	0.25	-0.07	-0.06	-0.94	-0.75	0.13	1.00	0.74	0.16	0.10	0.98	0.21	0.04	0.09	0.16
	prod_vol_temp	-0.32	0.66	-0.03	0.00	-0.38	-0.41	-0.05	0.21	0.37	-0.13	-0.71	-0.78	-0.16	0.71	0.74	1.00	-0.14	0.73	0.78	0.80	0.69	0.72
log_presion	-0.25	-0.14	0.04	-0.01	-0.00	-0.01	0.00	0.08	0.01	0.03	0.40	0.17	-0.10	0.00	0.16	-0.14	1.00	-0.20	-0.01	-0.18	-0.20	-0.19	1.00
	log_volumen	-0.12	0.12	-0.04	0.03	-0.30	-0.34	-0.06	0.25	0.31	-0.13	-0.98	-0.17	0.55	0.97	0.10	0.73	-0.20	1.00	0.14	0.99	0.99	1.00
log_temperatura	-0.35	0.83	-0.01	-0.02	-0.28	-0.28	-0.01	0.07	0.25	-0.07	-0.14	-0.99	-0.74	0.13	0.98	0.78	-0.01	0.1					

