

REPORTE TÉCNICO DE SELECCIÓN E IMPLEMENTACIÓN DE MODELO

Alvarez Forero Fabian Camilo
Alvarez Linares Laura Alejandra
Gutierrez Garcia Carlos Alberto
Sanchez Rozo D'Sharlie

1. Propuesta

Contugas, empresa dedicada a la distribución de gas natural, necesita vigilar de manera continua las lecturas de presión, temperatura y volumen de sus clientes industriales para detectar desviaciones que puedan anticipar fugas, fallos o consumos anómalos, entre otros. El prototipo fachada propuesto responde a esta necesidad sobre la base de los datos históricos suministrados por la propia compañía: propone, por un lado, un paper de análisis descriptivo que documenta los rangos normales y evidencia los primeros hallazgos de comportamiento atípico; y, por otro, una herramienta de monitoreo que permite ingresar nuevos registros y, mediante un modelo entrenado con las mismas variables, emitir un diagnóstico en tiempo real (normal/anómalo) para cada cliente. El desarrollo del proyecto busca responder a la necesidad de Contugas, acotando el alcance a lo que puede implementarse como ejercicio académico durante el curso Proyecto Aplicado en Analítica de Datos de la Maestría en Inteligencia Analítica de Datos de la Universidad de los Andes, según lo definido en el prototipo fachada y documentado en este reporte.

Este informe se centra principalmente en la selección e implementación de los modelos que permiten identificar los registros anómalos. Contugas suministró un histórico de lecturas de presión, temperatura, volumen y fecha por cliente, sin ningún indicador que señale cuándo ocurrió una anomalía. Con esa limitación, la estrategia que se cree factible es la detección de anomalías no supervisada: aprender primero lo que se podría llamar un comportamiento normal del sistema directamente de la estructura multivariada de esos cuatro campos y, a partir de ahí, asignar a cada nueva lectura una puntuación de rareza que se traduzca en una alerta.

1.1 Modelos propuestos

Para materializar este enfoque sin etiquetas, se seleccionan dos algoritmos no supervisados que se complementan: uno orientado a detectar desviaciones globales en el comportamiento conjunto de presión-temperatura-volumen y otro enfocado en anomalías que solo son raras dentro del contexto inmediato de cada cliente. La tabla siguiente resume cómo funciona cada modelo, por qué se ajusta a las restricciones del proyecto académico y qué valor concreto aporta a Contugas.

Modelo	¿Qué hace?	¿Por qué se ajusta al contexto?	¿Qué nos proporciona?
Isolation Forest (IF)	Construye múltiples árboles de partición aleatoria y mide cuántas divisiones necesita cada registro para quedar	Cobertura global: detecta combinaciones extremas simultáneas de presión-temperatura-volumen.	Puntuación global de rareza por registro y longitud media del camino, facilitando la

Modelo	¿Qué hace?	¿Por qué se ajusta al contexto?	¿Qué nos proporciona?
	aislado; los puntos que se aíslan rápido reciben alta puntuación de anomalía.	Escalable: se entrena en segundos con volúmenes horarios. Sin etiquetas: aprende el patrón normal directamente de los datos.	explicación de alertas al equipo operativo.
Local Outlier Fact (LOF)	Calcula la densidad local de cada lectura respecto a sus vecinos más cercanos y marca outliers donde esa densidad es sustancialmente menor.	Sensibilidad local: descubre desviaciones sutiles que son raras solo frente a la historia inmediata de cada cliente. Complemento de IF: captura cambios graduales o contextuales que podrían preceder fallos. Sin etiquetas: sigue el mismo esquema no supervisado.	Puntuación de rareza local priorizada por cliente y momento, aumentando la probabilidad de detectar anomalías encubiertas.

En conjunto, Isolation Forest y LOF cubren anomalías globales y locales, maximizando la probabilidad de identificar desviaciones operativas dentro de las ocho semanas del proyecto académico.

2 Desarrollo

2.1 Descripción de la fuente de datos

La información proporcionada por Contugas proviene de sensores instalados en la red de distribución de gas natural para clientes industriales. Fue compartida en un formato de hoja de cálculo compatible con Excel, dividido en hojas, en donde cada una contiene información de cada cliente para las siguientes variables:

- Fecha: marca temporal de fecha y hora.
- Presión: bar
- Temperatura: °C (Grados Celsius)
- Volumen: m3 (Metro Cúbico)

2.2 Análisis de integridad y estructura

Para facilitar el análisis se recorrieron todas las pestañas y se concatenaron sus registros en un solo dataframe, añadiendo la columna cliente con el nombre correspondiente a cada hoja. El resultado final es una tabla unificada en la que cada fila representa una medición horaria y cuyas columnas son:

- Fecha: marca temporal de fecha y hora.
- Presión: bar
- Temperatura: °C (Grados Celsius)
- Volumen: m3 (Metro Cúbico)
- Cliente: nombre del cliente industrial (nombre de la hoja que proviene)

En el dataframe final se observa:

- Se cuenta con 847960 registros y 5 columnas.
- Cada cliente tiene datos completos desde el 14 de enero de 2019 hasta el 31 de diciembre de 2023.
- No se encontraron valores nulos en las variables principales (Presión, Temperatura, Volumen).
- Los clientes registran datos en un rango entre 41000 y 43500 cada uno.

2.3 Análisis Exploratorio de los datos

2.3.1 Estadísticas generales:

Se calcularon métricas estadísticas descriptivas como la media, mediana, desviación estándar, y cuartiles para cada variable. Observando que:

- La Presión tiene baja variabilidad (desviaciones estándar menores a 1), lo que sugiere estabilidad operativa.
- La Temperatura muestra un rango amplio (-5°C a 50°C), con posibles valores atípicos.
- El Volumen presenta alta variabilidad y valores extremos significativos.

2.3.2 Análisis de variables físicas

Se elaboraron diagramas de caja (box plots) por cliente para cada variable (presión, temperatura y volumen) de modo que, en una sola vista, se comparan la mediana, la dispersión típica y los valores atípicos de cada usuario, facilitando la detección de diferencias operativas y tendencias entre clientes.

- **Volumen:** Para los clientes 4, 9, 10, 13, 15 y 19, el valor del cuartil 1, la mediana y el cuartil 3 es cero o cercano a cero, indicando que una gran proporción de los registros tiene valores muy bajos. Sin embargo, presentan una gran cantidad de valores atípicos que se alejan significativamente del rango inter cuartil. Estos valores atípicos podrían ser considerados como posibles anomalías, aunque es necesario determinar si corresponden a eventos operativos legítimos o errores de medición. En contraste, los demás clientes muestran distribuciones más completas (Ilustración 2). Aunque también presentan algunos valores atípicos.
- **Presión:** La mayoría de los clientes tienen una mediana de presión entre 16 y 18 bar, con mínimos no inferiores a 13 bar, lo que indica un comportamiento consistente. Sin embargo, los clientes 3 y 11 presentan valores significativamente más bajos y estables, con medianas alrededor de 3.5 bar y muy poca dispersión, lo cual es inusual en comparación con los demás. La desviación estándar de la presión es menor que 1 para todos los clientes, lo que sugiere que la presión es regulada y mantenida constante, con datos altamente concentrados alrededor de la mediana. Esto refleja estabilidad en las operaciones del sistema. Los clientes con mayor rango inter cuartil (diferencia entre el cuartil 1 y 3) son 7, 8, 12 y 16, mientras que todos los clientes presentan valores atípicos. La falta de información sobre las características físicas de las tuberías, como su material o profundidad, podría ser clave para entender las variaciones en los valores de presión y sus límites operativos (como se muestra en la Ilustración 3).
- **Temperatura:** Aunque los comportamientos varían entre clientes, para la mayoría el 50% de las mediciones de temperatura se encuentran entre 20°C y 30°C , indicando estabilidad en las operaciones. El análisis global de los registros de temperatura muestra que el promedio (25.20°C) es muy cercano a la mediana (25.38°C), sugiriendo una distribución simétrica y un rango estable de funcionamiento para la mayoría de los clientes. Se observan valores atípicos en varios clientes, lo que podría estar relacionado con condiciones específicas de las tuberías o factores externos. Además, se desconoce la profundidad de operación de las tuberías, que podría influir en las temperaturas mínimas y máximas aceptables (Ilustración 4).

2.3.3 Variables a lo Largo del Tiempo

Con base en los gráficos de Volumen, Presión y Temperatura, para todos los periodos dados (Ilustración 5), se observa:

- La temperatura muestra un comportamiento oscilatorio para todos los clientes, probablemente influido por la variación de la temperatura exterior según la época del año.
- En el caso de la presión, los clientes 1, 2, 4, 5, 6, 14, 17, 18, 19 y 20 presentan una disminución progresiva en 2023, con un comportamiento descendente desde el inicio hasta el final del año.
- Los clientes 9, 10, 13 y 15 tienen alta variabilidad en sus registros de presión, mientras que los clientes 3, 7, 8, 11, 12 y 16 muestran un comportamiento más estable en cuanto a mediciones.
- Todos los clientes presentan alta variabilidad en el registro de volumen a lo largo del tiempo, lo que podría estar relacionado con patrones de consumo o variaciones operativas.
- El cliente 2 no registró datos durante un periodo de 2019, lo cual podría indicar una falla en el sistema de adquisición de datos o ausencia de consumo durante ese tiempo.

Los valores atípicos en las variables Volumen, Presión y Temperatura destacan como posibles anomalías, pero requieren un análisis adicional para determinar si son legítimos o indicativos de fallas. La ausencia de registros del cliente 2 en 2019 resalta la necesidad de validar la integridad del sistema de monitoreo. Además, la falta de información sobre características contextuales de las tuberías, como material, profundidad o antigüedad, podría ser crucial para comprender mejor las variaciones observadas. Por último, las variaciones temporales, como la disminución de presión en 2023 para ciertos clientes, sugieren patrones estacionales o posibles anomalías operativas que deben investigarse más a fondo.

2.4 Transformaciones y generación de variables

Además de la transformación inicial para facilitar el análisis y uso de la información en un solo dataframe, con el fin de enriquecer los datos y capturar patrones complejos de comportamiento, se aplicó una función de ingeniería de características que generó nuevas variables a partir de las existentes. Estas transformaciones se realizaron sobre las variables Presión, Volumen, Temperatura, Fecha y la variable categórica Cliente. A continuación, se describen los principales grupos de variables creadas y su propósito:

2.4.1 Variables temporales

Tienen como objetivo capturar efectos relacionados con el horario o el día:

Variable	Descripción
hour	Hora del día (0 a 23)
day_of_week	Día de la semana (0=lunes, 6=Domingo)
is_weekend	Indicador si el registro es sábado o domingo (1)

Tabla 1. Variables temporales

2.4.2 Variables cíclicas

Representan periodicidad (día/semana) respetando continuidad cíclica, estas transformaciones evitan rupturas artificiales en modelo:

Variable	Descripción
sin_hour, cos_hour	Representación cíclica de la hora del día

sin_day_of_week, cos_day_of_week	Representación cíclica del día de la semana
-------------------------------------	---

Tabla 2. Variables cíclicas

2.4.3 Relaciones físicas entre variables

Con estas se quiere capturar interacciones que pueden indicar comportamientos anómalos:

Variable	Fórmula
ratio_pres_vol	Presión / Volumen
ratio_pres_temp	Presión / Temperatura
ratio_vol_temp	Volumen / Temperatura
prod_pres_vol	Presión × Volumen
prod_pres_temp	Presión × Temperatura
prod_vol_temp	Volumen × Temperatura

Tabla 3. Relaciones físicas entre variables

2.4.4 Transformaciones logarítmicas

Con esta transformación se desea disminuir la asimetría de la distribución y estabilizar la varianza:

Variable	Transformación
log_presion	$\log(1 + \text{Presión})$
log_volumen	$\log(1 + \text{Volumen})$
log_temperatura	$\log(1 + \text{Temperatura})$

Tabla 4. Transformación Logarítmica

2.4.5 Estadísticas fila a fila

Se busca capturar patrones de variación en los registros individuales:

Variable	Descripción
mean_three	Promedio entre presión, volumen y temperatura
std_three	Desviación estándar entre las tres variables
max_three, min_three	Máximo y mínimo entre las tres variables

Tabla 5. Estadísticas de variación fila a fila

2.4.6 Imputación de valores faltantes

Ya que el conjunto de datos de origen no presenta valores nulos, no se realiza ningún tipo de imputación de valores faltantes.

2.4.7 Análisis de correlación entre variables originales y transformadas

Para evaluar la utilidad informativa de las nuevas variables generadas, se calculó una matriz de correlación entre las variables originales (Presión, Volumen, Temperatura) y varias de sus transformaciones derivadas. La visualización del heatmap (Ilustración 6) nos muestra:

- Fuertes correlaciones esperadas entre variables transformadas y sus originales. Por ejemplo, Volumen muestra alta correlación con `prod_vol_temp`, `log_volumen`, `mean_three` y `std_three`, lo cual es coherente con su magnitud dominante en el sistema.
- Relaciones no lineales complementarias, como `ratio_pres_vol` y `std_three`, presentan correlaciones negativas con varias otras variables, lo que indica que capturan patrones distintos a los que se observan con los valores crudos.
- Variables resumen como `mean_three` y `std_three` están altamente correlacionadas con múltiples atributos. Esto sugiere que condensan información clave de cada observación y pueden ser útiles para detectar desviaciones agregadas.
- Aunque algunas variables presentan colinealidad alta (como `log_volumen`, `prod_vol_temp` y `max_three`), estas pueden aportar valor individual en distintos contextos, y su redundancia será gestionada en la fase de modelado.
- Este análisis respalda que las transformaciones aplicadas no son redundantes, sino que contribuyen a enriquecer la representación del comportamiento físico-operativo del sistema, lo cual resulta clave para un enfoque robusto de detección de anomalías.

Para explorar visualmente las relaciones entre variables originales (Presión, Volumen, Temperatura) y algunas de sus transformaciones, se generó un gráfico de dispersión pareado (pairplot) con una muestra representativa, donde se observa (Ilustración 7) lo siguiente:

- Las relaciones esperadas bien definidas como Presión y `prod_pres_temp` muestran una relación lineal clara, como era de esperarse, dado que una variable es producto directo de la otra; para volumen y `log_volumen` también mantienen una forma funcional creciente, pero no completamente lineal (se ve la curvatura esperada por la transformación logarítmica).
- Las transformaciones logarítmicas ayudan a suavizar la dispersión en el caso de variables como `log_volumen` o `log_presion` muestran distribuciones menos sesgadas en las diagonales KDE (aunque aún con colas), esto indica que estas transformaciones son útiles para estabilizar varianza en futuras etapas de modelado.
- Las variables como `std_three` y `ratio_pres_vol` muestran patrones menos definidos, no se observan agrupamientos evidentes ni relaciones claras con otras variables, esto no es necesariamente negativo, ya que estas variables pueden estar capturando outliers o ruido no lineal que será útil para los modelos de detección de anomalías.
- Densidades multimodales, en los gráficos diagonales (KDE), se observan distribuciones multimodales especialmente en `log_volumen`, `mean_three` y `std_three`, lo que sugiere presencia de subgrupos operativos o heterogeneidad en los registros por cliente o condición operativa.

Este gráfico no busca encontrar relaciones estrictamente lineales, sino confirmar que las transformaciones aplicadas introducen diversidad estructural en los datos. Algunas variables resumen (`std_three`, `mean_three`) y no lineales (`ratio_pres_vol`) podrían capturar desviaciones atípicas que no son visibles con las variables crudas, lo que las vuelve candidatas clave en el modelado no supervisado.

2.4.8 Escalamiento de variables

Para asegurar que todos los modelos funcionen bajo igualdad de condiciones se aplicó `StandardScaler()` a todas las variables numéricas del conjunto final de características (X). Esta transformación es importante porque:

- Equilibra la contribución de cada variable: LOF se basa en distancias euclidianas y, sin escalado, una feature con rango amplio dominaría la métrica, ocultando patrones relevantes en las demás.
- Reduce sesgos en las particiones de Isolation Forest: los cortes aleatorios se eligen dentro del rango de cada atributo; si uno presenta valores muy grandes, se aísla con menos divisiones y genera falsos positivos.

- Mejora la estabilidad numérica y la interpretación de puntajes: al homogenizar magnitudes—sobre todo después de aplicar logaritmos y ratios—los decision scores son comparables y permite fijar umbrales más coherentes.

2.4.9 Codificación de variable categórica

Se utiliza one-hot encoding para transformar la variable categórica Cliente en múltiples columnas binarias, lo que resulta imprescindible para que los algoritmos de detección propuestos puedan procesar correctamente esta información; además, al generar indicadores independientes para cada cliente, se evita introducir un orden artificial entre ellos y se permite al modelo aprender patrones normales específicos de cada cliente, mejorando la capacidad de identificar desviaciones relevantes por usuario.

2.5 Selección y justificación de las variables predictoras y objetivo

2.5.1 Variables predictoras

El conjunto final de características (X) se construyó aplicando transformaciones diseñadas para enriquecer la representación del fenómeno físico observado. Las variables se agrupan así:

- Variables originales :
 - Presión, Volumen, Temperatura: estas son las señales base medidas por los sensores en campo, y representan directamente las condiciones del sistema.
- Transformaciones estadísticas y algebraicas:
 - Ratios Presion / Volumen, Presion / Temperatura, Volumen / Temperatura: proveen una visión relativa entre magnitudes físicas, útil para detectar desbalances anómalos.
 - Productos cruzados Presion * Volumen, Presion * Temperatura, Volumen * Temperatura: capturan interacciones no lineales entre señales, permitiendo al modelo detectar anomalías por combinaciones.
 - Log-transformaciones seguras ($\log_{10}$): log_presion, log_volumen, log_temperatura. Ayudan a estabilizar varianzas y reducir el sesgo de magnitudes altas.
 - Estadísticos fila a fila mean_three, std_three, min_three, max_three: describen el comportamiento conjunto de las tres señales por registro, útil para evaluar consistencia interna.
- Temporales y cíclicas:
 - Hora del día (hour), día de la semana (day_of_week), fin de semana (is_weekend): representaciones seno y coseno para capturar patrones horarios y semanales. Estas variables permiten detectar si una anomalía ocurre en momentos atípicos, como noches o días no laborables.
- Codificación por cliente: se incluyó esta codificación para permitir que el modelo reconozca patrones específicos de comportamiento por cliente, sin introducir sesgos.

El conjunto de variables fue diseñado para:

- Capturar múltiples dimensiones del comportamiento físico del sistema de gas.
- Aumentar la capacidad del modelo para encontrar patrones atípicos, no solo en valores individuales, sino también en relaciones entre ellos.
- Mantener interpretabilidad, permitiendo entender por qué un punto fue marcado como anómalo.
- Este enfoque balancea la complejidad con la robustez, mejorando la sensibilidad del modelo a anomalías reales sin sobre ajustar a ruido temporal o fluctuaciones benignas.

2.5.2 Variable objetivo

La variable objetivo es un indicador binario que señala si un registro horario de presión, volumen y temperatura en un cliente industrial se clasifica como “normal” (1) o “anómalo” (−1).

2.5.2.1 Anomalías por análisis de cuantiles

Dado que el conjunto de datos carece de etiquetas reales de anomalía, se generó una variable objetivo sintética mediante un enfoque de pseudo-etiqueta basado en el rango intercuartílico móvil (Rolling IQR). Para cada cliente y cada variable (presión, volumen, temperatura), se calculan los cuantiles Q1 y Q3 en una ventana móvil de w horas, y se marca un registro como pseudo-anomalía si supera los límites:

$$IQR = Q_3 - Q_1$$

$$\text{Límite inferior} = Q_1 - 1.5 \cdot IQR$$

Para ventana móvil de tamaño w :

$$Q^1(t) = \text{percentil 25 de } x_{t-w+1}, \dots, x_t$$


$$Q^3(t) = \text{percentil 75 de } \{x_{t-w+1}, \dots, x_t\}$$

$$y_i = 1, \quad \text{si } x_i < Q^1(t) - 1.5 \cdot IQR(t) \text{ o } x_i > Q^3(t) + 1.5 \cdot IQR(t); 0, \text{ en otro caso}$$

Estos indicadores univariados se combinan en una pseudo-etiqueta binaria (1 = posible anomalía, 0 = normal).

Para decidir el rango de valores de contaminación a explorar en el grid search de Isolation Forest y LOF, se evaluó cómo varía la proporción de pseudo-anomalías al cambiar la ventana de 6 a 168 horas:

Ilustración 1. Pseudo-anomalías generadas vs Tamaño de ventana móvil



- **6–24 h:** alta sobre-detección de fluctuaciones cotidianas (> 19 %).
- **48 h en adelante:** la tasa se estabiliza en torno al 11–12 %.
- **120 h:** ligera caída, por exceso de suavizado.

Al utilizar ventanas móviles mayores a 48 h la proporción de pseudo-anomalías se estabiliza alrededor del 11–12 %, ese rango sirve como referencia para definir los valores iniciales de contamination en el grid search (por ejemplo, explorar entre 8 % y 15 %).

2.6 Entrenamiento de modelos y evaluación

2.6.1 Pseudo-etiquetado Rolling-IQR

Dado que no se cuenta con etiquetas reales de anomalía, se utilizó un mecanismo de pseudo-etiquetado basado en el análisis de valores extremos mediante el rango intercuartílico (IQR) móvil. Este procedimiento no tiene la intención de servir como verdad absoluta, sino de estimar un porcentaje base de registros inusuales (alrededor del 11%), que a su vez permitió definir el rango de valores del hiperparámetro contamination en el entrenamiento de modelos no supervisados.

2.6.2 Búsqueda de hiperparámetros (Grid Search)

Se entrenaron dos modelos de detección de anomalías: Isolation Forest e Isolation basado en vecinos (Local Outlier Factor - LOF). Para ambos, se exploraron distintos niveles de contamination entre 2.5% y 15%. En el caso de LOF, además se ajustó el número de vecinos (n_neighbors) entre 5, 10 y 20. Esta grilla de combinaciones busca entender la sensibilidad de cada modelo a sus parámetros principales y encontrar la configuración más coherente con el comportamiento esperado del sistema.

2.6.3 Validación cruzada temporal

Para evaluar los modelos, se utilizó validación cruzada basada en series temporales, dividiendo el conjunto de datos en tres cortes secuenciales, donde cada fold de validación contiene datos posteriores en el tiempo a los de entrenamiento. Esta aproximación imita el flujo real de operación del sistema, asegurando que el modelo solo vea datos pasados para hacer predicciones sobre registros futuros.

2.6.4 Métricas utilizadas para la comparación de modelos

Como se trata de un problema no supervisado, las métricas no dependen de etiquetas reales, sino que buscan evaluar la capacidad de los modelos para identificar patrones atípicos de manera consistente y significativa.

- Gap Score: mide qué tan separadas están las predicciones consideradas normales y anómalas en términos de su puntuación de anomalía. Una mayor separación indica mejor capacidad de discriminar entre comportamientos normales y atípicos.

$$\text{Gap Score} = \frac{|\widetilde{x_{\text{normal}}} - \widetilde{x_{\text{anom}}}|}{\text{IQR}(x) + \varepsilon}$$

Donde:

- $\widetilde{x_{\text{normal}}}$ es la mediana de los scores de las observaciones normales.
- $\widetilde{x_{\text{anom}}}$ es la mediana de los scores de las observaciones anómalas.
- $\text{IQR}(x)$ es el rango intercuartílico de todos los scores.
- ε es un valor pequeño para evitar división por cero.

- Coeficiente de bimodalidad: evalúa qué tan bimodal es la distribución de los puntajes de anomalía. Un patrón bimodal sugiere que el modelo está generando dos grupos bien diferenciados de registros, lo cual es deseable en la detección de outliers.

$$BC = \frac{g^2 + 1}{k}$$

Donde:

- g es el coeficiente de asimetría (skewness) de la distribución de los puntajes de anomalía.
- k es la curtosis (kurtosis) de la misma distribución, medida con la fórmula de Pearson (no centrada en cero).
- Cobertura de extremos: determina qué proporción de las anomalías detectadas coincide con registros que son extremos en al menos una de las variables medidas (según su puntaje z). Esto ayuda a verificar que las detecciones reflejen comportamientos verdaderamente inusuales.

$$\text{ExtremeCoverage} = \frac{\sum_{i \in \mathcal{A}} \mathbf{1} \left(\max_j |z_{ij}| > \tau \right)}{|\mathcal{A}|}$$

- Tasa de anomalías detectadas: indica el porcentaje total de registros marcados como anómalos por el modelo. Se espera que este valor se mantenga cercano al nivel de contamination configurado y que sea coherente con el porcentaje estimado inicialmente a través del pseudo-etiquetado.

Estas métricas se promediaron a través de los tres folds de validación temporal, generando un marco sólido para comparar objetivamente el desempeño de las distintas configuraciones de modelo. La evaluación se centra en la separación estadística entre normales y anómalos, la estabilidad del modelo y la relevancia de las detecciones frente a comportamientos extremos reales.

3 Resultados

3.1 Resultados para cada iteración

Detector	Contamination	n_neighbors	Gap_CV	Bimodality_CV	Ext_Cov_CV	Anomaly_Rate
if	0.025	–	1.694	0.247	0.801	0.062
if	0.050	–	1.586	0.247	0.696	0.084
if	0.075	–	1.531	0.247	0.640	0.106
if	0.100	–	1.487	0.247	0.596	0.131
if	0.125	–	1.449	0.247	0.558	0.157
if	0.150	–	1.408	0.247	0.527	0.184
lof	0.025	5	0.963	0.372	0.161	0.929
lof	0.050	5	0.960	0.372	0.160	0.940
lof	0.075	5	0.957	0.372	0.159	0.946
lof	0.100	5	0.956	0.372	0.159	0.951
lof	0.125	5	0.954	0.372	0.159	0.954
lof	0.150	5	0.953	0.372	0.158	0.957
lof	0.025	10	1.045	0.348	0.161	0.928
lof	0.050	10	1.041	0.348	0.160	0.939
lof	0.075	10	1.039	0.348	0.160	0.944
lof	0.100	10	1.037	0.348	0.159	0.948
lof	0.125	10	1.035	0.348	0.159	0.952
lof	0.150	10	1.034	0.348	0.159	0.955
lof	0.025	20	1.012	0.240	0.162	0.921
lof	0.050	20	1.007	0.240	0.161	0.931
lof	0.075	20	1.005	0.240	0.160	0.937
lof	0.100	20	1.002	0.240	0.160	0.942
lof	0.125	20	1.000	0.240	0.160	0.945
lof	0.150	20	0.999	0.240	0.160	0.948

Tabla 6. Resultados de validación cruzada para modelos Isolation Forest y LOF con distintas configuraciones

Se evaluaron múltiples configuraciones de modelos de detección de anomalías, centrando la atención en Isolation Forest (IF) y Local Outlier Factor (LOF), ajustando el parámetro de contamination y, en el caso de LOF, el número de vecinos (n_neighbors). Para cada configuración, se midieron tres métricas no supervisadas: *gap score*, *coeficiente de bimodalidad*, y *cobertura de extremos*, junto con la proporción de puntos clasificados como anómalos (*anomaly rate*).

Los resultados indican que IF con contamination = 0.025 ofrece la mayor separación entre normales y anómalos y la mayor cobertura de valores extremos, pero con una tasa de anomalías muy conservadora. A medida que aumenta el valor de contamination, se incrementa el porcentaje de puntos detectados como anómalos, aunque con una leve degradación de las métricas.

3.2 Comparación entre modelos respecto a las métricas definidas

Al comparar modelos, se establecieron tres criterios principales: (1) mantener un *gap score* mayor a 1.5, (2) asegurar una cobertura de extremos significativa (al menos 65%), y (3) lograr una tasa de anomalías en un rango operativo sostenible (entre 7% y 12%).

Con base en estos criterios, se seleccionó Isolation Forest con contamination = 0.050 como el modelo óptimo. Esta configuración conserva una buena capacidad de separación y cobertura (~70%), al tiempo que eleva la

tasa de detección de anomalías al 8.4%, lo que permite una mejor cobertura de eventos potencialmente relevantes sin saturar los sistemas de monitoreo ni generar una carga excesiva para el equipo de operaciones.

En contraste, aunque IF con $\text{contamination} = 0.025$ presenta mejores métricas de precisión, su tasa de detección es demasiado baja (6%), lo que podría implicar que se dejen pasar eventos anómalos relevantes. Por otro lado, todas las configuraciones evaluadas con LOF mostraron tasas de detección excesivamente altas (>90%), lo que las vuelve operativamente inviables.

3.3 Debilidades o errores en los resultados:

Se identificaron algunas limitaciones en el comportamiento de los modelos:

- LOF mostró una sobre-detección sistemática, etiquetando más del 90% de las observaciones como anómalas, lo que sugiere una falta de discriminación útil. Esto podría deberse a la sensibilidad del modelo a la dimensionalidad elevada (producto del one-hot encoding por cliente), o a una configuración inadecuada del parámetro $n_neighbors$.
- Sensibilidad de IF al parámetro contamination : se observó que pequeñas variaciones en este valor tienen un impacto notable en la cobertura de extremos y la tasa de anomalías.
- Pseudoetiquetas basadas en IQR: aunque el enfoque de pseudoetiquetado guía la evaluación de modelos, podría no captar completamente los patrones anómalos operativos reales, especialmente en periodos con variabilidad natural elevada o condiciones atípicas planificadas (como mantenimientos o pruebas).

3.4 Ajustes y mejoras a los modelos

Para fortalecer los resultados y la robustez del sistema propuesto, se plantean las siguientes mejoras:

- Ajuste fino del parámetro contamination en Isolation Forest: explorar valores intermedios como 0.045 o 0.055 para analizar su efecto sin necesidad de cambios estructurales.
- Incremento leve de $n_estimators$ (por ejemplo, de 100 a 150) para mejorar la estabilidad de las predicciones, manteniendo el resto de los parámetros fijos.
- Curva de decisión (decision_function) con umbral ajustable: permitir definir un umbral post-hoc para marcar anomalías, lo cual da flexibilidad operativa sin reentrenar el modelo.
- Filtrar atributos poco informativos (como algunas columnas Cliente_ con baja frecuencia) para reducir ruido y mejorar la respuesta del modelo.

3.5 Impacto en el problema de negocio

La adopción del modelo Isolation Forest con calibración tendrá un impacto significativo en la operación de Contugas:

- Permitirá un monitoreo continuo y automatizado de variables críticas como presión, volumen y temperatura en la red.
- Generará alertas tempranas ante comportamientos inusuales, facilitando acciones correctivas preventivas.
- Mejorará la eficiencia del mantenimiento, priorizando intervenciones según patrones reales de riesgo.
- Aumentará la confiabilidad del servicio y la satisfacción de clientes industriales, al prevenir fallos antes de que generen impacto comercial.

Este sistema basado en un enfoque no supervisado es escalable y puede adaptarse a nuevas estaciones, cambios en la red o condiciones externas sin requerir bases históricas completamente etiquetadas.

4 Análisis Exploratorio

Partimos del output del modelo *Isolation Forest*, que etiquetó el 2,5 % de las 847.960 lecturas (21.199 registros) como “anómalas”. El propósito de este análisis es transformar esa señal binaria en conocimiento operativo: entender por qué cada lectura quedó fuera de rango, cómo se distribuyen las alertas a lo largo de la red y qué patrones comunes replican los eventos críticos. El desarrollo del análisis se realizó con Python, en el archivo *anomaly* que se encuentra en el repositorio del proyecto. Los resultados y conclusiones fueron recopilados en el Paper, que hace parte de los entregables. Aquí se hace una descripción de los procesos realizados, para revisar los resultados ir al Paper.

4.1 Proceso Metodológico

4.1.1 Análisis Global de Anomalías

- Se compararon las distribuciones de presión, caudal y temperatura entre registros normales y anómalos mediante diagramas de violín, identificando los rangos que el modelo clasifica como atípicos (presión < 5 bar o > 18 bar, caudal 100–150 m³, temperatura cerca de 30 °C).
- Se construyó una matriz de correlación sobre el subconjunto anómalo (incluidas variables derivadas y ciclos temporales) para confirmar relaciones físicas esperadas, como la caída de presión ante picos de caudal.

4.1.2 Revisión uno a uno por cliente

- Para cada una de las 20 estaciones se calculó la tasa interna de anomalías, la proporción sobre el total y la frecuencia media entre alertas.
- Se tradujeron los resultados en rangos operativos precisos para cada cliente (por ejemplo, caudales muy bajos con presión estable en ciertas estaciones o picos de flujo con caída de presión en otras).

4.1.3 Selección de configuración y Clustering

- Se evaluaron configuraciones de *K-means* apoyadas en la gráfica de codo (Elbow Plot) y en el coeficiente de silueta, confirmando que tres clusters equilibran compactación y separación.
- Se entrenó *K-means* sobre las tres variables originales más la codificación de cliente, para capturar patrones físicos y contextuales.
- Se validó visualmente la separación de grupos mediante PCA, proyectando centros de cada cluster en dos componentes principales.

4.1.4 Resultados principales

- Tasa de anomalías: el modelo identificó el 2,5 % de las lecturas como atípicas, un volumen operativo revisable.
- Patrones globales: las desviaciones se concentran en tres escenarios físicos recurrentes:
 - Flujo muy bajo con presión estable
 - Fluctuaciones moderadas y sostenidas de caudal
 - Picos de caudal con caída brusca de presión
- Clusters operativos: cada uno de estos tres grupos resume miles de alertas bajo un “tipo” de evento que los técnicos pueden reconocer y priorizar de forma homogénea, independientemente de la estación.

5 Prototipo funcional: aplicación web para diagnóstico en tiempo real

Con el fin de cerrar el ciclo del modelo desarrollado y facilitar su uso por parte del personal técnico de Contugas, se construyó una aplicación web de escritorio basada en Streamlit. Esta herramienta permite ingresar nuevas lecturas de presión, temperatura y volumen asociadas a un cliente, y devuelve un diagnóstico inmediato indicando si el registro es normal o se considera una anomalía según el modelo entrenado.

5.1 Funcionalidades implementadas

- Interfaz amigable, en español, con instrucciones claras.
- Campos de entrada editables para volumen (m^3), presión (bar) y temperatura ($^{\circ}C$).
- Selector de cliente desde una lista desplegable.
- Botón de análisis que ejecuta el modelo local sin conexión a internet.
- Diagnóstico binario destacado en color (verde para “Normal”, rojo para “Anomalía”).

5.2 Pruebas de validación

- Tiempo de respuesta promedio medido: **0.9 segundos**.
- Se verificó que la app puede ejecutarse sin acceso a internet.
- Se comprobó que cada campo valida su tipo de dato correctamente (ej. decimales).
- El resultado se presenta inmediatamente después del análisis, resaltado visualmente.

5.3 Captura de la herramienta

La imagen muestra la interfaz de usuario de una aplicación web titulada "Detector de Anomalías". En la parte superior, hay un encabezado azul con el logo de "contugas" y el título. Debajo, se encuentra una sección "Guía de Uso" con cinco pasos numerados que explican cómo utilizar la herramienta. El formulario principal incluye un campo "Fecha-Hora" con el valor "25/05/2025 04:28 p. m.", un selector de "Cliente" con "CLIENTE1" seleccionado, y tres campos de entrada para "Volumen (m³)", "Presión (bar)" y "Temperatura (°C)". Cada campo tiene un ejemplo de valor (150.5, 5.5 y 25.5 respectivamente) y una instrucción de formato. En la parte inferior, hay un botón azul que dice "Analizar Registro".

Figura 1. Interfaz principal del prototipo web para detección de anomalías. Vista general de la aplicación web local desarrollada. El formulario permite ingresar valores de presión, volumen y temperatura, seleccionar el cliente, y obtener un diagnóstico inmediato

5.4 Pruebas de validación por cliente: comportamiento operativo detectado

Como cierre del proceso de experimentación, se desplegó una aplicación web local con el modelo entrenado y calibrado (Isolation Forest con contamination = 0.050), que permite al usuario ingresar nuevos valores operativos y obtener en segundos un dictamen de normalidad o anomalía.

Para validar que el modelo no solo responde técnicamente bien, sino que genera resultados coherentes en un entorno de uso real, se realizaron pruebas con registros específicos de distintos clientes. El objetivo fue comprobar que los patrones detectados en el análisis exploratorio (y detallados en el paper) se manifiestan de forma consistente al usar la app.

5.4.1 Casos de prueba seleccionados

La siguiente tabla presenta algunos ejemplos de registros utilizados en la aplicación web local, evaluando si el resultado entregado por el modelo coincide con los patrones previamente detectados en el análisis exploratorio.

Table 1: Casos de prueba por cliente

Cliente	Registro ingresado	Resultado de la app	Coherencia con análisis previo
C-3	Presión = 3.6 bar, Volumen = 80 m ³ , Temp. = 24°C	Anomalía	Coincide: presión por debajo de 3.7 fue marcada como anómala.
C-12	Presión = 4 bar, Volumen = 150.5 m ³ , Temp. = 25°C	Normal	Coincide: comportamiento dentro del rango esperado para este cliente.
C-5	Presión = 10 bar, Volumen = 8 m ³ , Temp. = 15°C	Anomalía	Coincide: descenso térmico pronunciado acompañado de bajo flujo.
C-1	Presión = 17 bar, Caudal = 100 m ³ , Temp. = 25°C	Normal	Coincide: cliente sin registros anómalos previos.
C-4	Presión = 4 bar, Volumen = 150.5 m ³ , Temp. = 25°C	Anomalía	Coincide: combinación de caudal y presión inusualmente bajos respecto al historial.

A continuación, se muestra la inferencia realizada en la aplicación web para un caso del cliente C-3, donde el modelo detecta una anomalía coherente con el patrón identificado previamente

Fecha-Hora: 25/05/2025 04:28 p. m.

Cliente: CLIENTE3

Volumen (m³): 80

Presión (bar): 3.6

Temperatura (°C): 24

Ingrese el valor con al menos un decimal (ej: 150.5)

Ingrese el valor con al menos un decimal (ej: 5.5)

Ingrese el valor con al menos un decimal (ej: 25.5)

Analizar Registro

Resultado del Análisis

ANOMALÍA DETECTADA

Figura 2. {Aplicación Streamlit mostrando el diagnóstico para un registro del cliente C-3 con presión = 3.6 bar, volumen = 80 m³ y temperatura = 24 °C. El resultado "Anomalía Detectada" coincide con lo reportado en el análisis exploratorio

6 Anexos

Ilustración 2. Gráfico de caja por cliente para Volumen (m3)




Ilustración 3. Gráfico de caja por cliente para Presión (bar)




Ilustración 4. Gráfico de caja por cliente para Temperatura (°C)









Ilustración 5. Histórico de Volumen, Temperatura y Presión por Cliente

















Ilustración 6. Mapa de correlación (Sin variables temporales)




Ilustración 7. Gráfico de dispersión de variables

